

1. Problema 1

Implementa el algoritmo de descenso más pronunciado utilizando los siguientes tamaños de paso:

- (a) Valor fijo:

$$\alpha_k := 1e - 4$$

es decir, un valor pequeño.

- (b) Aproximación 1:

$$\alpha_k := \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{H}_k \mathbf{g}_k}$$

- (c) Aproximación 2:

$$\alpha_k := \frac{\mathbf{g}_k^T \mathbf{g}_k \alpha_{k-1}^2}{2(f_{k-1} - f_k + \alpha_{k-1} \mathbf{g}_k^T \mathbf{g}_k)}$$

$\alpha_0 = 1e - 4$ (un valor pequeño).

1.1. Resumen

En este trabajo, se implementa el algoritmo de descenso más pronunciado utilizando tres métodos diferentes para el cálculo del tamaño de paso. Se analiza el desempeño de cada método en la minimización de funciones y se presentan los resultados obtenidos.

1.2. Introducción

El descenso más pronunciado es un método iterativo utilizado para minimizar funciones diferenciables. Su principio básico es moverse en la dirección opuesta al gradiente de la función objetivo, con un tamaño de paso adecuado. En este trabajo, se comparan tres estrategias distintas para la selección del tamaño de paso, evaluando su desempeño en problemas de optimización.

1.3. Método \ Algoritmo

Implementamos el algoritmo de descenso más pronunciado con tres diferentes métodos para calcular el tamaño del paso α_k :

- (a) Valor fijo:

$$\alpha_k := 1e - 4$$

es decir, un valor pequeño.

- (b) Aproximación 1:

$$\alpha_k := \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{H}_k \mathbf{g}_k}$$

(c) Aproximación 2:

$$\alpha_k := \frac{\mathbf{g}_k^T \mathbf{g}_k \alpha_{k-1}^2}{2(f_{k-1} - f_k + \alpha_{k-1} \mathbf{g}_k^T \mathbf{g}_k)}$$

donde $\alpha_0 = 1e - 4$.

Algorithm 1 Descenso de Gradiente

```

1: Entrada:  $f(x)$  (función objetivo),  $\alpha$  (tasa de aprendizaje),  $\epsilon$  (tolerancia),  $x_0$  (punto
   inicial), max iteraciones  $N$ 
2: Salida:  $x^*$  (mínimo encontrado)
3: Inicializar  $x \leftarrow x_0$ 
4: for  $i = 1$  hasta  $N$  do
5:   Calcular gradiente:  $g \leftarrow \nabla f(x)$ 
6:   Actualizar:  $x \leftarrow x - \alpha g$ 
7:   if  $|g| < \epsilon$  then
8:     Devolver  $x$                                      ▷ Convergencia alcanzada
9:   end if
10: end for
11: Devolver  $x$                                        ▷ Máximo número de iteraciones alcanzado

```

1.4. Resultados

Se hicieron dos experimentos para comprobar si el algoritmo funciona correctamente. A continuación se presentan las funciones que se buscan minimizar:

- Sea $x \in \mathbb{R}$ y $f_1(x) = x^2 + 5x + 7$, el gradiente de esta función es $\nabla f_1(x) = 2x + 5$ y el hessiano es $H_{f_1} = 2$.

Para cada punto inicial aleatorio:

Ejecutar Descenso por Gradiente con función f_1 , gradiente y hessiano
 Imprimir punto inicial y resultado

Método numérico	Punto inicial	x_n	Error	$f(x_n)$	Iteraciones
1	-4	-2.500	10^{-12}	0.750	18
	9	-2.500	10^{-12}	0.750	20
	4	-2.500	10^{-12}	0.750	19
	0	-2.500	10^{-12}	0.750	19
	-3	-2.500	10^{-12}	0.750	18
2	-4	-2.500	10^{-12}	0.750	1
	8	-2.500	10^{-12}	0.750	1
	0	-2.500	10^{-12}	0.750	1
	0	-2.500	10^{-12}	0.750	1
	-7	-2.500	10^{-12}	0.750	1
3	-3	-2.519	10^{-12}	0.750	999
	-8	-2.706	10^{-12}	0.792	999
	-9	-2.743	10^{-12}	0.809	999
	1	-2.369	10^{-12}	0.767	999
	-5	-2.594	10^{-12}	0.759	999

Cuadro 1: Resultados del Experimento 0

- Sea $x = (x_0, x_1) \in \mathbb{R}^2$ y $f_2(x) = x_0^2 + 7x_0 + x_1^2 - 4x_1 + 3$, el gradiente es $\nabla f_2(x) = (2x_0 + 7, 2x_1 - 4)$ y el hessiano es $H_{f_2} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$.

Para cada método numérico:

Para cada punto inicial aleatorio:

Ejecutar Descenso por Gradiente con la función f2, gradiente y hessiano;

Imprimir resultados: punto inicial,

valor de x_n y $f(x_n)$;

Método numérico	Punto inicial	x_n	Error	$f(x_n)$	Iteraciones
1	(-9, -10)	(-3.5, 2.0)	10^{-12}	-13.25	20
	(1, 1)	(-3.5, 2.0)	10^{-12}	-13.25	19
	(6, -1)	(-3.5, 2.0)	10^{-12}	-13.25	20
	(5, 4)	(-3.5, 2.0)	10^{-12}	-13.25	19
	(4, 8)	(-3.5, 2.0)	10^{-12}	-13.25	20
2	(1, 9)	(-3.5, 2.0)	10^{-12}	-13.25	1
	(-8, -6)	(-3.5, 2.0)	10^{-12}	-13.25	1
	(8, -4)	(-3.5, 2.0)	10^{-12}	-13.25	1
	(-2, -4)	(-3.5, 2.0)	10^{-12}	-13.25	1
	(7, -7)	(-3.5, 2.0)	10^{-12}	-13.25	1
3	(3, 7)	(-3.2569, 2.1870)	10^{-12}	-13.1559	999
	(-2, -9)	(-3.4439, 1.5885)	10^{-12}	-13.0775	999
	(9, 4)	(-3.0324, 2.0748)	10^{-12}	-13.0258	999
	(-4, 1)	(-3.5187, 1.9626)	10^{-12}	-13.2483	999
	(-3, 4)	(-3.4813, 2.0748)	10^{-12}	-13.2441	999

Cuadro 2: Resultados del Experimento 1

1.5. Conclusiones

Como se puede observar, en problemas simples, el algoritmo presenta dificultades para converger en ciertas situaciones, lo que depende del paso, del punto inicial y del valor de α . Esto se evidenciará en los siguientes problemas. Para garantizar la óptima convergencia, sería necesario realizar múltiples experimentos. Sin embargo, se comprobó que, para los ejercicios de ejemplo, cualquier aproximación de α con un paso de 0.5 logró la convergencia en una iteración en ambos experimentos.

2. Problema 2

Obtén el mínimo de la función de Rosenbrock para $n = 128$ utilizando el algoritmo de descenso más pronunciado con los tamaños de paso implementados.

- (a) Usa el punto inicial $\mathbf{x}^0$ proporcionado a continuación.
- (b) Además, ejecuta el algoritmo para un punto inicial $\mathbf{x}^0$ seleccionado aleatoriamente.
- (c) En ambos casos, grafica (k, f_k) y $(k, \|\mathbf{g}_k\|)$.

Función de Rosenbrock

$$f(\mathbf{x}) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$$

$$\mathbf{x}^0 = [-1.2, 1, 1, \dots, 1, -1.2, 1]^T$$

$$\mathbf{x}^* = [1, 1, \dots, 1, 1]^T$$

$$f(\mathbf{x}^*) = 0$$

2.1. Resumen

En este problema, se busca encontrar el mínimo de la función de Rosenbrock utilizando el algoritmo de descenso más pronunciado. Este método se aplica primero con un punto inicial específico y luego con un punto aleatorio. Para cada uno de estos casos, se evalúa el comportamiento del algoritmo en términos de iteraciones y se grafica la evolución de la función objetivo y el gradiente. Los resultados se comparan utilizando tres diferentes enfoques para el tamaño del paso: uno constante, uno basado en la aproximación de Newton-Raphson y otro basado en una regla de ajuste iterativo.

2.2. Introducción

La función de Rosenbrock es una función de prueba comúnmente utilizada para evaluar algoritmos de optimización. Su forma no convexa y la existencia de un mínimo global bien definido la convierten en una función adecuada para probar el rendimiento de diferentes técnicas de optimización. El objetivo de este ejercicio es usar el algoritmo de descenso más pronunciado para encontrar el mínimo de esta función y evaluar su desempeño bajo distintas estrategias para el cálculo del tamaño del paso.

2.3. Método \ Algoritmo

$$f(\mathbf{x}) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$$

donde $\mathbf{x} = (x_1, x_2, \dots, x_n)$ es un vector en $\mathbb{R}^n$.

2.3.1. Gradiente de la función de Rosenbrock

El gradiente de la función de Rosenbrock se obtiene derivando parcialmente con respecto a cada x_i :

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

donde cada componente está dado por:

$$\frac{\partial f}{\partial x_1} = -400(x_2 - x_1^2)x_1 - 2(1 - x_1)$$

$$\frac{\partial f}{\partial x_i} = 200(x_i - x_{i-1}^2) - 400(x_{i+1} - x_i^2)x_i - 2(1 - x_i), \quad \forall i \in \{2, \dots, n-1\}$$

$$\frac{\partial f}{\partial x_n} = 200(x_n - x_{n-1}^2)$$

2.3.2. Hessiana de la función de Rosenbrock

La matriz Hessiana de la función de Rosenbrock se define como:

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

La estructura de la matriz Hessiana es:

$$H = \begin{bmatrix} h_{11} & h_{12} & 0 & \cdots & 0 \\ h_{21} & h_{22} & h_{23} & \cdots & 0 \\ 0 & h_{32} & h_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & h_{n-1,n} \\ 0 & 0 & 0 & h_{n,n-1} & h_{nn} \end{bmatrix}$$

donde:

$$h_{ii} = -400(x_{i+1} - x_i^2) + 800x_i^2 + 2, \quad \forall i \in \{1, \dots, n-1\}$$

$$h_{i,i+1} = h_{i+1,i} = -400x_i, \quad \forall i \in \{1, \dots, n-1\}$$

$$h_{nn} = 200$$

2.4. Resultados




Figura 2.1: Optimización de la función de Rosenbrock evaluada, con punto inicio dado $x_0 = [-1.2, 1, 1, \dots, 1, -1.2]$




Figura 2.2: Gradiente de la función Rosenbrock evaluada, con punto inicio dado $x_0 = [-1.2, 1, 1, \dots, 1, -1.2]$




Figura 2.3: Optimización de la función de Rosenbrock evaluada, con punto inicio aleatorio




Figura 2.4: Gradiante de la función Rosenbrock evaluada, con punto inicio aleatorio

Método	Iteraciones	$\ x_n\ $	$f(x_n)$	Error
Evaluaciones con un punto dado				
Alpha constante	99999	11.270	4.010	1×10^{-7}
Newton-Raphson	99999	11.298	3.987	1×10^{-7}
Regla iterativa	99999	11.334	6.030	1×10^{-7}
Evaluaciones con un punto aleatorio				
Alpha constante	99999	6.227	89.308	1×10^{-5}
Newton-Raphson	99999	11.959	0.002	1×10^{-5}
Regla iterativa	99999	9.327	238.765	1×10^{-5}

Cuadro 3: Resultados generales de los métodos con diferentes puntos iniciales

Método	x_n (resumido)
Evaluaciones con un punto dado	
Alpha constante	$[-0.993, 0.997, 0.998, \dots, 0.754, 0.754, 0.754]$
Newton-Raphson	$[-0.993, 0.997, 0.998, \dots, 0.963, 0.963, 0.963]$
Regla iterativa	$[-0.993, 0.997, 0.998, \dots, 0.019, 0.019, 0.019]$
Evaluaciones con un punto aleatorio	
Alpha constante	$[-0.993, 0.997, 0.998, \dots, 0.000, 0.000, 0.000]$
Newton-Raphson	$[1.000, 1.000, 1.000, \dots, 0.919, 0.919, 0.919]$
Regla iterativa	$[-0.831, 0.701, 0.498, \dots, 0.039, 0.039, 0.039]$

Cuadro 4: Valores de x_n resumidos para cada método

2.5. Conclusiones

Como se puede observar, el método de Newton-Raphson obtuvo los mejores resultados en el punto dado. Además, en ciertos experimentos no contemplados en este reporte, se

observó que la convergencia dependía significativamente del punto inicial. En uno de estos experimentos, el método logró aproximarse al objetivo. Por lo tanto, se puede concluir que, para obtener resultados satisfactorios en estos métodos, es necesario realizar una cantidad considerable de experimentación.

3. Problema 3

Dado un conjunto de puntos $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m \in \mathbb{R}^n$, el algoritmo de escalado multidimensional (MDS) encuentra un nuevo conjunto de puntos $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_m \in \mathbb{R}^d$ en una dimensión inferior $d < n$ tal que

$$\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_m = \arg \min_{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m} \sum_{i < j} (d_{ij} - \|\mathbf{z}_i - \mathbf{z}_j\|)^2$$

donde $\mathbf{y}_i, \mathbf{z}_i \in \mathbb{R}^d$ y d_{ij} es la distancia entre $\mathbf{x}_i$ y $\mathbf{x}_j$, por ejemplo, la distancia euclidiana

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$$

- Usa el algoritmo de descenso más pronunciado con tamaño de paso fijo para resolver el problema de MDS. En este ejemplo, los puntos dados $\mathbf{x}_i \in \mathbb{R}^4$ son las filas del conjunto de datos Iris proporcionado `iris.csv` (flores de iris de tres especies, ver comentario a continuación) y $\mathbf{y}_i, \mathbf{z}_i \in \mathbb{R}^2$. Genera un **gráfico de dispersión** de los puntos $\mathbf{z}_i \in \mathbb{R}^2$, con una leyenda que represente las especies de las flores.
- Comentario: El conjunto de datos Iris es un conjunto de datos bien conocido en aprendizaje automático y estadística, frecuentemente utilizado para tareas de clasificación y reconocimiento de patrones. Consiste en 150 muestras de flores de iris, cada una descrita por cuatro características:
 - Longitud del sépalo (cm)
 - Ancho del sépalo (cm)
 - Longitud del pétalo (cm)
 - Ancho del pétalo (cm)

Cada muestra está etiquetada con una de las tres especies de iris:

- Setosa
 - Versicolor
 - Virginica
- Puedes leer los puntos $\mathbf{x}_i \in \mathbb{R}^4, i = 0, 1, \dots, 149$ (es decir, $m = 150$) con:

```
import pandas as pd
X = pd.read_csv('iris.csv').iloc[:,0:4].values
Specie = pd.read_csv('iris.csv').iloc[:,4].values
```

Nota que $\mathbf{x}_i = X[i, :]^T \in \mathbb{R}^4$ y la especie correspondiente es *Specie[i]*.

3.1. Resumen

En este trabajo se implementa el algoritmo de escalado multidimensional (MDS) utilizando el método de descenso más pronunciado. Se busca representar los datos del conjunto de flores de iris en un espacio de menor dimensión, preservando lo mejor posible la estructura de distancias entre puntos. Se presentan los resultados en forma de gráficos de dispersión que permiten visualizar las relaciones entre las muestras y sus respectivas especies.

3.2. Introducción

El escalado multidimensional (MDS) es una técnica de reducción de dimensionalidad que busca encontrar una representación en un espacio de menor dimensión preservando la estructura de las distancias entre puntos. Dado un conjunto de puntos en $\mathbb{R}^n$, el objetivo es encontrar su representación en $\mathbb{R}^d$ minimizando la discrepancia entre las distancias originales y las inducidas en el nuevo espacio. Este problema puede resolverse mediante métodos de optimización numérica, como el descenso más pronunciado.

El conjunto de datos Iris, utilizado en este trabajo, es un conjunto clásico en el aprendizaje automático que contiene medidas de sépalos y pétalos de tres especies de flores. Reducir su dimensionalidad a $d = 2$ permite visualizar la distribución de las muestras y analizar su agrupamiento.

3.3. Método \ Algoritmo

El problema de MDS se modela como la minimización de la función objetivo:

$$\sum_{i < j} (d_{ij} - \|z_i - z_j\|)^2$$

donde d_{ij} representa la distancia entre los puntos originales en $\mathbb{R}^4$, mientras que $\|z_i - z_j\|$ es la distancia entre los puntos en $\mathbb{R}^2$.

Para resolver este problema, se implementa el método de descenso más pronunciado con tamaño de paso fijo. Se utilizan las siguientes funciones:

- Función objetivo $f(z)$, que mide la discrepancia entre las distancias en el espacio original y el espacio reducido.
- Gradiente de la función objetivo $\nabla f(z)$, que proporciona la dirección de mayor descenso.
- Hessiano de la función objetivo $Hf(z)$, que permite capturar la curvatura de la función.

El algoritmo se implementa de la siguiente manera:

- Se inicializa el conjunto de puntos z en $\mathbb{R}^2$.
- Se calcula el gradiente $\nabla f(z)$.
- Se actualiza la posición de los puntos con un tamaño de paso fijo:

$$z^{(k+1)} = z^{(k)} - \alpha \nabla f(z^{(k)})$$

- Se repite el proceso hasta alcanzar la convergencia.

3.4. Resultados




Figura 3.1: Gradiente de la función Rosenbrock evaluada, con punto inicio aleatorio

3.5. Conclusiones

Se observa una diferencia en los datos, donde se nota una separación entre *Virginica* y *Versicolor*, mientras que *Setosa* se encuentra claramente apartada. Si se lograra encontrar un punto inicial más adecuado o ajustar un paso fijo óptimo, los resultados podrían ser aún más diferenciables.