

1. Calcule y clasifique los puntos críticos de la siguiente función:

$$f(x_1, x_2) = (x_1^2 + x_2^2 - 1)^2 + (x_2^2 - 1)^2$$

Muestra la función usando Python.

Solución. Calculamos el gradiente:

$$\nabla f = \begin{bmatrix} 4(x_1^2 + x_2^2 - 1)x_1 \\ 4(x_1^2 + x_2^2 - 1)x_2 + 4(x_2^2 - 1)x_2 \end{bmatrix}.$$

Igualemos a cero:

$$4(x_1^2 + x_2^2 - 1)x_1 = 0.$$

De esta ecuación obtenemos dos casos:

- $x_1 = 0$, o
- $x_1^2 + x_2^2 = 1$.

Para la segunda ecuación:

$$4(x_1^2 + x_2^2 - 1)x_2 + 4(x_2^2 - 1)x_2 = 0.$$

Factorizamos:

$$4x_2 [(x_1^2 + x_2^2 - 1) + (x_2^2 - 1)] = 0.$$

Obtenemos:

- $x_2 = 0$, o
- $x_1^2 + 2x_2^2 = 2$.

Calculamos la matriz Hessiana:

$$H_f = \begin{bmatrix} 8x_1^2 + 4(x_1^2 + x_2^2 - 1) & 8x_1x_2 \\ 8x_1x_2 & 16x_2^2 + 4(x_1^2 + x_2^2 - 1) + 4(x_2^2 - 1) \end{bmatrix}.$$

Evaluamos en el punto $(0, 0)$:

$$H_f(0, 0) = \begin{bmatrix} -4 & 0 \\ 0 & -8 \end{bmatrix}.$$

Calculamos su determinante:

$$\det(H_f(0, 0)) = (-4)(-8) - (0)(0) = 32 > 0.$$

Como la primera componente diagonal es negativa, $H_f(0,0)$ es definida negativa, por lo que $(0,0)$ es un **máximo local**. Resolviendo el sistema de ecuaciones $x_1^2 + x_2^2 = 1$ y $x_1^2 + 2x_2^2 = 2$ primero despejamos x_2^2 de la primera ecuación y sustituimos en la segunda

$$x_2^2 = 1 - x_1^2$$

$$x_1^2 + 2(1 - x_1^2) = 2$$

$$x_1^2 + 2 - 2x_1^2 = 2$$

$$-x_1^2 = 0$$

ahora despejamos x_1^2 de la primera ecuación y sustituimos en la segunda

$$x_1^2 = 1 - x_2^2$$

$$1 - x_2^2 + 2x_2^2 = 2$$

$$1 + x_2^2 = 2$$

$$x_2^2 = 1$$

$$x_2 = \pm 1$$

resulta en dos puntos críticos que son $(0,1)$ y $(0,-1)$ Evaluamos en el punto $(0,1)$:

$$H_f(0,1) = \begin{bmatrix} 0 & 0 \\ 0 & 16 \end{bmatrix}.$$

Calculamos su determinante:

$$\det(H_f(0,1)) = (0)(16) - (0)(0) = 0.$$

Evaluamos en el punto $(0,-1)$:

$$H_f(0,-1) = \begin{bmatrix} 0 & 0 \\ 0 & 16 \end{bmatrix}.$$

Calculamos su determinante:

$$\det(H_f(0,-1)) = (0)(16) - (0)(0) = 0.$$

Estos dos puntos anteriores no son concluyentes. Los puntos críticos son:

- $(0,0)$ es un máximo local.
- $(0,1)$ y $(0,-1)$ no son concluyentes.




Figura 0.1: Gráfico con los puntos críticos

■

2. Sea A una matriz positiva definida. Muestra que:

$$A_{ij} < \frac{A_{ii} + A_{jj}}{2}$$

Si A es positiva definida, esto implica que para cualquier vector $x \in \mathbb{R}^n$, tenemos que:

$$x^T A x > 0 \quad \text{para } x \neq 0.$$

Consideremos el vector $x = e_i - e_j$, donde e_i y e_j son los vectores canónicos de la base estándar. Entonces, el producto $x^T A x$ se expande como sigue:

$$x^T A x = (e_i - e_j)^T A (e_i - e_j).$$

Expandiendo el producto, obtenemos:

$$x^T A x = e_i^T A e_i - e_i^T A e_j - e_j^T A e_i + e_j^T A e_j.$$

Dado que $e_i^T A e_i = A_{ii}$, $e_j^T A e_j = A_{jj}$, y $e_i^T A e_j = A_{ij}$ (como A es simétrica), tenemos:

$$x^T A x = A_{ii} + A_{jj} - 2A_{ij}.$$

Como A es positiva definida, sabemos que $x^T A x > 0$ para cualquier $x \neq 0$. Por lo tanto, se cumple:

$$A_{ii} + A_{jj} - 2A_{ij} > 0.$$

Reorganizando esta ecuación, obtenemos:

$$2A_{ij} < (A_{ii} + A_{jj}),$$

lo que implica que:

$$A_{ij} < \frac{A_{ii} + A_{jj}}{2}.$$

3. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Muestra que para todo x, y se cumple:

$$f(y) \geq f(x) + \alpha(f(x) - f(z)),$$

donde $\alpha > 0$ y $z = x + \frac{1}{\alpha}(x - y)$.

Por la convexidad de f , sabemos que para todo $x, y \in \mathbb{R}^n$ y $\alpha > 0$, se cumple la desigualdad:

$$f(z) \leq f(x) + \frac{1}{\alpha}(f(x) - f(y)),$$

donde $z = x + \frac{1}{\alpha}(x - y)$.

A partir de esta desigualdad, despejamos para obtener la expresión deseada:

$$\begin{aligned} f(z) &\leq f(x) + \frac{1}{\alpha}(f(x) - f(y)) \\ \alpha(f(z) - f(x)) &\leq f(x) - f(y) \\ -\alpha(f(z) - f(x)) &\geq -f(x) + f(y) \\ f(x) - \alpha(f(z) - f(x)) &\leq f(y) \\ f(y) &\geq f(x) + \alpha(f(x) - f(z)). \end{aligned}$$

Así, hemos demostrado que:

$$f(y) \geq f(x) + \alpha(f(x) - f(z)).$$

4. Suponga que se usa el algoritmo de gradiente descendente con tamaño de paso fijo para minimizar la función:

$$f(x) = \frac{1}{2}x^T \begin{bmatrix} 3/2 & 2 \\ 0 & 3/2 \end{bmatrix} x + x^T \begin{bmatrix} 3 \\ -1 \end{bmatrix} - 22$$

Determine el rango de valores que puede tomar el tamaño de paso para que el algoritmo converja al minimizador.

Solución. Definimos la matriz A y el vector b como:

$$A = \begin{bmatrix} 3/2 & 2 \\ 0 & 3/2 \end{bmatrix}, \quad b = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

El gradiente de la función $f(x)$ es:

$$\nabla f(x) = \frac{1}{2}(A + A^T)x + b.$$

El método de descenso de gradiente con tamaño de paso fijo α se expresa como:

$$x_{i+1} = x_i - \alpha \nabla f(x_i).$$

Sustituyendo el gradiente, obtenemos:

$$x_{i+1} = x_i - \alpha \left(\frac{1}{2}(A + A^T)x_i + b \right).$$

Buscamos que el gradiente sea cero en el punto óptimo x^* , es decir:

$$\nabla f(x^*) = \frac{1}{2}(A + A^T)x^* + b = 0.$$

Restando el punto óptimo en ambos lados de la iteración del gradiente descendente, tenemos:

$$x_{n+1} - x^* = x_n - \alpha \left(\frac{1}{2}(A + A^T)x_n + b \right) - x^*.$$

Como $b = -\frac{1}{2}(A + A^T)x^*$, sustituyendo en la ecuación anterior, obtenemos:

$$x_{n+1} - x^* = x_n - x^* - \alpha \left(\frac{1}{2}(A + A^T)x_n - \frac{1}{2}(A + A^T)x^* \right).$$

Simplificando, llegamos a:

$$x_{n+1} - x^* = \left(I - \alpha \frac{1}{2}(A + A^T) \right) (x_n - x^*).$$

Para que x_n converja a x^* , la norma espectral de la matriz $I - \alpha \frac{1}{2}(A + A^T)$ debe ser menor que 1:

$$\left\| I - \alpha \frac{1}{2}(A + A^T) \right\| < 1.$$

Una cota para la norma espectral es el radio espectral de la matriz, definido como:

$$\rho(B) := \max\{|\lambda| : \lambda \text{ es un autovalor de } B\}.$$

Aplicando esto a la desigualdad $\|I - \alpha \frac{1}{2}(A + A^T)\| < 1$, obtenemos:

$$\rho\left(I - \alpha \frac{1}{2}(A + A^T)\right) \leq \left\|I - \alpha \frac{1}{2}(A + A^T)\right\| < 1.$$

El radio espectral de $I - \alpha \frac{1}{2}(A + A^T)$ es:

$$\rho\left(I - \alpha \frac{1}{2}(A + A^T)\right) = \max \left|1 - \alpha \frac{1}{2}\lambda_i\right|,$$

donde λ_i son los autovalores de $A + A^T$.

Por lo tanto, la desigualdad se satisface si:

$$\max \left|1 - \alpha \frac{1}{2}\lambda_i\right| < 1.$$

Esto implica:

$$-1 < 1 - \alpha \frac{1}{2}\lambda_{\max} < 1.$$

Despejando α , obtenemos:

$$\begin{aligned} -1 &< 1 - \alpha \frac{1}{2}\lambda_{\max} < 1 \\ -2 &< -\alpha \frac{1}{2}\lambda_{\max} < 0 \\ 0 &< \alpha \frac{1}{2}\lambda_{\max} < 2 \\ 0 &< \alpha < \frac{4}{\lambda_{\max}}. \end{aligned}$$

Para encontrar $\lambda_{\max}$, calculamos los autovalores de $A + A^T$ resolviendo:

$$\det(A + A^T - \lambda I) = \det\left(\begin{bmatrix} 3 - \lambda & 2 \\ 2 & 3 - \lambda \end{bmatrix}\right) = (3 - \lambda)^2 - 4 = 0.$$

Esto nos da los autovalores:

$$\lambda_1 = 1, \quad \lambda_2 = 5.$$

Por lo tanto, $\lambda_{\max} = 5$, y la cota superior para α es:

$$\alpha < \frac{4}{\lambda_{\max}} = \frac{4}{5}.$$

Finalmente, el rango de valores de α para que el algoritmo converja es:

$$0 < \alpha < \frac{4}{5}.$$

■

5. Demuestra que el siguiente conjunto:

$$S = \{x \mid |x^T y| \leq 1; x, y \in \mathbb{R}^n\}$$

es convexo.

Solución. sea $x_1, x_2 \in S$, y se cumpla que para todo $y \in \mathbb{R}^n$,

$$|x_1^T y| \leq 1, \quad |x_2^T y| \leq 1.$$

consideramos el punto $z = \lambda x_1 + (1 - \lambda)x_2$ y evaluamos $|z^T y|$

$$z^T y = (\lambda x_1 + (1 - \lambda)x_2)^T y$$

por linealidad del producto interno, y aplicando valor absoluto

$$|z^T y| = |\lambda x_1^T y + (1 - \lambda)x_2^T y|$$

usando desigualdad triangular

$$|z^T y| \leq |\lambda x_1^T y| + |(1 - \lambda)x_2^T y|$$

sacando λ y $1 - \lambda$ de los valores absolutos

$$|z^T y| \leq \lambda |x_1^T y| + (1 - \lambda) |x_2^T y|$$

dado que $|x_1^T y| \leq 1$ y $|x_2^T y| \leq 1$ se obtiene

$$|z^T y| \leq \lambda(1) + (1 - \lambda)(1) = \lambda + 1 - \lambda = 1$$

esto demuestra que $z \in S$ lo que implica que S es convexo. ■

6. Sea:

$$f(x) = \frac{1}{2} x^T Q x - b^T x$$

donde Q es simétrica y positiva definida. Si d_k es una dirección de descenso, calcule el tamaño de paso exacto:

$$\alpha_k^{MG} = \arg \min_{\alpha > 0} \|\nabla f(x_k + \alpha d_k)\|$$

Solución. Dada la función:

$$f(x) = \frac{1}{2} x^T Q x - b^T x,$$

su gradiente es:

$$\nabla f(x) = Qx - b.$$

Para encontrar el tamaño de paso α_k^{MG} , minimizamos la norma del gradiente en la dirección d_k :

$$\|\nabla f(x_k + \alpha d_k)\|^2 = \|Q(x_k + \alpha d_k) - b\|^2.$$

Expresamos la norma al cuadrado como un producto punto:

$$\|Q(x_k + \alpha d_k) - b\|^2 = (Q(x_k + \alpha d_k) - b)^T (Q(x_k + \alpha d_k) - b).$$

Desarrollamos el producto punto:

$$(Q(x_k + \alpha d_k) - b)^T (Q(x_k + \alpha d_k) - b) = (Qx_k + \alpha Qd_k - b)^T (Qx_k + \alpha Qd_k - b).$$

Expandimos la expresión:

$$\begin{aligned} (Qx_k + \alpha Qd_k - b)^T (Qx_k + \alpha Qd_k - b) &= (Qx_k)^T Qx_k + (Qx_k)^T (\alpha Qd_k) + (Qx_k)^T (-b) \\ &\quad + (\alpha Qd_k)^T Qx_k + (\alpha Qd_k)^T (\alpha Qd_k) + (\alpha Qd_k)^T (-b) \\ &\quad + (-b)^T Qx_k + (-b)^T (\alpha Qd_k) + (-b)^T (-b). \end{aligned}$$

Simplificamos cada término:

$$\begin{aligned} &= x_k^T Q^T Qx_k + \alpha x_k^T Q^T Qd_k - x_k^T Q^T b \\ &\quad + \alpha d_k^T Q^T Qx_k + \alpha^2 d_k^T Q^T Qd_k - \alpha d_k^T Q^T b \\ &\quad - b^T Qx_k - \alpha b^T Qd_k + b^T b. \end{aligned}$$

Dado que Q es simétrica ($Q = Q^T$), simplificamos:

$$\begin{aligned} &= x_k^T Q^2 x_k + \alpha x_k^T Q^2 d_k - x_k^T Qb \\ &\quad + \alpha d_k^T Q^2 x_k + \alpha^2 d_k^T Q^2 d_k - \alpha d_k^T Qb \\ &\quad - b^T Qx_k - \alpha b^T Qd_k + b^T b. \end{aligned}$$

Agrupamos términos semejantes:

$$\begin{aligned} \|\nabla f(x_k + \alpha d_k)\|^2 &= x_k^T Q^2 x_k + \alpha^2 d_k^T Q^2 d_k + b^T b \\ &\quad + 2\alpha x_k^T Q^2 d_k - 2\alpha d_k^T Qb - 2x_k^T Qb. \end{aligned}$$

Para encontrar el valor de α que minimiza esta expresión, derivamos con respecto a α e igualamos a cero:

$$\frac{d}{d\alpha} \|\nabla f(x_k + \alpha d_k)\|^2 = 2\alpha d_k^T Q^2 d_k + 2x_k^T Q^2 d_k - 2d_k^T Qb = 0.$$

Resolviendo para α :

$$\begin{aligned} 2\alpha d_k^T Q^2 d_k + 2x_k^T Q^2 d_k - 2d_k^T Qb &= 0. \\ 2\alpha d_k^T Q^2 d_k &= 2d_k^T Qb - 2x_k^T Q^2 d_k. \\ \alpha &= \frac{d_k^T Qb - x_k^T Q^2 d_k}{d_k^T Q^2 d_k}. \end{aligned}$$

Notando que $\nabla f(x_k) = Qx_k - b$, podemos reescribir α como:

$$\alpha = -\frac{d_k^T Q \nabla f(x_k)}{d_k^T Q^2 d_k}.$$

■